

ЛАБОРАТОРНАЯ РАБОТА №1

Исследование влияния предобработки данных на качество линейной регрессии

Студенты: Альтшуль Даниил Евгеньевич
Вохмяков Данила Никитич

Группа: J3117

Вариант: 17

test_size: 0.23

random_state: 46

Цель работы

Предложить среднеквадратическую аппроксимацию табличной функции многих переменных, проанализировать чувствительность точного решения к ошибкам округления, проверить сходимость расчётных и исходных данных.

Теоретические сведения

2.1 Линейная регрессия

Линейная регрессия - метод моделирования зависимости между зависимой переменной y и одной или несколькими независимыми переменными X :

$$y = Xw + \varepsilon$$

где w - вектор весов (коэффициентов), ε - случайная ошибка.

Оптимальные веса находятся через нормальное уравнение МНК:

$$w^* = (X^T X)^{-1} X^T y$$

что эквивалентно решению системы $X^T X w = X^T y$ методом наименьших квадратов.

МНК (метод наименьших квадратов) ищет такие веса w , чтобы сумма квадратов ошибок была минимальной:

$$\|Xw - y\|^2 \rightarrow \min$$

Задача линейной регрессии сводится к решению системы линейных уравнений (СЛАУ) вида $Aw = c$, где:

$$A = X^T X, \quad c = X^T y$$

2.2 Методы предобработки данных

StandardScaler - стандартизация признаков: вычитание среднего (`with_mean`) и деление на стандартное отклонение (`with_std`). Приводит признаки к единому масштабу, что уменьшает число обусловленности матрицы и повышает численную стабильность.

PolynomialFeatures - генерация полиномиальных признаков заданной степени `degree`. Позволяет моделировать нелинейные зависимости в рамках линейной регрессии. При `degree=2` из признаков $[a, b]$ получаем $[1, a, b, a^2, ab, b^2]$.

2.3 Метрики качества

MAE (Mean Absolute Error) - средняя абсолютная ошибка:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Интерпретируется в единицах целевой переменной (тысячах долларов). Чем меньше, тем лучше.

Число обусловленности матрицы $X^T X$ - отношение максимального сингулярного числа к минимальному. Большое значение ($> 10^6$) указывает на численную нестабильность и чувствительность решения к малым ошибкам.

Ход работы

3.1 Описание датасета

Использован датасет Boston Housing (файл `train.csv`). Целевая переменная: `medv` - медианная стоимость жилья в тысячах долларов. Признаки (13 столбцов): криминальная обстановка (`crim`), доля жилых зон (`zn`), доля нежилых площадей (`indus`), наличие реки (`chas`), концентрация оксидов азота (`nox`), среднее число комнат (`rm`), доля старого жилья (`age`), расстояние до центров занятости (`dis`), индекс транспортной доступности (`rad`), налог на собственность (`tax`), соотношение учитель/ученик (`ptratio`), доля чёрного населения (`b`), процент малообеспеченных жителей (`lstat`). Столбец ID исключался из признаков.

3.2 Листинг кода

Импорт библиотек

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
import numpy as np
from sklearn.preprocessing import StandardScaler, PolynomialFeatures
from sklearn.model_selection import train_test_split
```

Загрузка данных и параметры варианта

```
train_df = pd.read_csv('train.csv')
TEST_SIZE = 0.23
RANDOM_STATE = 46
```

Реализация линейной регрессии через МНК

```
class LinearRegression:
    def __init__(self):
        self.w = None
        self.b = None
        self.coef_ = None

    def fit(self, x, y):
        x = np.asarray(x, dtype=float)
        y = np.asarray(y, dtype=float).ravel()
        # добавляем единичный столбец для свободного члена
        ones = np.ones((x.shape[0], 1))
        x_b = np.column_stack([x, ones])
        #
        # решение нормального уравнения МНК через псевдообратную матрицу
        #
        #  $w* = \text{pinv}(X) @ y$ , где  $\text{pinv}(X) = (X^T X)^{-1} X^T$ 
        coef = np.linalg.pinv(x_b) @ y
        self.w = coef[:-1]
```

```

        self.b = coef[-1]
        self.coef_ = self.w

    def predict(self, x):
        return x @ self.w + self.b

# функция вычисления средней абсолютной ошибки
def mean_absolute_error(y_true, y_pred):
    y_true = np.asarray(y_true, dtype=float).ravel()
    y_pred = np.asarray(y_pred, dtype=float).ravel()
    return np.mean(np.abs(y_pred - y_true))

```

Основной эксперимент - цикл по 6 комбинациям

```

# комбинации параметров предобработки согласно заданию
rules_from_pdf = [
    {'mean': False, 'std': False, 'degree': 1},
    {'mean': True, 'std': False, 'degree': 1},
    {'mean': False, 'std': True, 'degree': 1},
    {'mean': True, 'std': True, 'degree': 1},
    {'mean': True, 'std': True, 'degree': 2},
    {'mean': True, 'std': True, 'degree': 3},
]
res = []

for i, rls in enumerate(rules_from_pdf, 1):
    # выделяем признаки и целевую переменную
    features = train_df.drop(columns=["medv", "ID"])
    target = train_df[["medv"]]

    # разбиваем на обучающую и тестовую выборки
    X_train, X_test, y_train, y_test = train_test_split(
        features, target, test_size=TEST_SIZE, random_state=
        RANDOM_STATE)

    # масштабирование признаков
    scaler = StandardScaler(with_mean=rls['mean'], with_std=rls['std']
        ])
    X_train = scaler.fit_transform(X_train)
    X_test = scaler.transform(X_test)

    # генерация полиномиальных признаков
    # include_bias=False - модель сама добавляет столбец единиц fit
    poly = PolynomialFeatures(degree=rls['degree'], include_bias=
        False)
    X_train = poly.fit_transform(X_train)
    X_test = poly.transform(X_test)

    # обучение модели через МНК
    model = LinearRegression()
    model.fit(X_train, y_train)

    # вычисление метрик

```

```

mae_train = mean_absolute_error(y_train, model.predict(X_train))
mae_test  = mean_absolute_error(y_test,  model.predict(X_test))
# числообусловленностиматрицы  $X^T * X$ 
cond = np.linalg.cond(X_train.T @ X_train)

res.append({'No': i, 'mean': rls['mean'], 'std': rls['std'],
            'degree': rls['degree'], 'mae train': round(mae_train
            , 4),
            'mae test': round(mae_test, 4), 'cond': f'{cond:.2e}'
            })

table = pd.DataFrame(res)

```

3.3 Таблица результатов экспериментов

№	mean	std	degree	MAE train	MAE test	Число обусл.
1	False	False	1	3.4628	3.3667	2.36e+08
2	True	False	1	3.4628	3.3667	1.13e+07
3	False	True	1	3.4628	3.3667	1.25e+05
4	True	True	1	3.4628	3.3667	9.42e+01
5	True	True	2	1.5763	90.2035	1.08e+17
6	True	True	3	0.0000	16.5916	1.25e+21

Анализ результатов

4.1 Графики



Рис. 1: MAE train и MAE test для каждой конфигурации




Рис. 2: Число обусловленности матрицы $X^T X$ в логарифмической шкале

4.2 Ответы на вопросы

- Как масштабирование признаков влияет на качество модели?

При $\text{degree}=1$ масштабирование не изменяет MAE train и MAE test: во всех конфигурациях 1-4 значения идентичны (3.46 и 3.37 соответственно). Однако масштабирование кардинально снижает число обусловленности матрицы $X^T X$: без нормировки оно составляет 2.36×10^8 , а при включении обоих параметров ($\text{mean}=\text{True}$, $\text{std}=\text{True}$) падает до 9.42×10^1 . Это означает, что решение становится значительно более численно устойчивым.

- Как изменяется качество при увеличении степени полинома?

При переходе с $\text{degree}=1$ на $\text{degree}=2$ MAE train снижается с 3.46 до 1.58 - модель начинает лучше описывать обучающую выборку. Однако MAE test вырастает до 90.2, что говорит о сильном ухудшении обобщающей способности. При $\text{degree}=3$ MAE train = 0 (идеальная подгонка), но MAE test = 16.59 - модель полностью запоминает обучающие данные и не обобщается на новые.

- Есть ли признаки переобучения (overfitting)?

Да, начиная с конфигурации №5 ($\text{degree}=2$). Признаки: MAE train резко падает при одновременном росте MAE test. При $\text{degree}=3$ разрыв максимальный: train = 0.0000 против test = 16.5916. Это классический паттерн переобучения.

- Как число обусловленности связано с качеством модели?

Большое число обусловленности указывает на численную нестабильность: матрица $X^T X$ близка к вырожденной, малые ошибки в данных приводят к большим ошибкам в весах. При $\text{degree}=2$: $\text{cond} = 1.08 \times 10^{17}$, при $\text{degree}=3$ - 1.25×10^{21} , что объясняет огромные MAE test. Масштабирование снижает cond на несколько порядков и стабилизирует решение.

- Какая комбинация параметров даёт наилучший результат на тестовой выборке?

Конфигурация №4: $\text{mean}=\text{True}$, $\text{std}=\text{True}$, $\text{degree}=1$. MAE test = 3.3667 - минимальное среди всех конфигураций, число обусловленности наименьшее (9.42×10^1). Модель не переобучена: MAE train $\approx$ MAE test.

4.3 Выводы о влиянии предобработки на качество модели

Стандартизация признаков (StandardScaler) не улучшает MAE при линейной модели, но существенно снижает число обусловленности, повышая численную стабильность. Полиномиальные признаки позволяют снизить ошибку на обучающей выборке, однако при $\text{degree} \geq 2$ без регуляризации неизбежно возникает переобучение. Оптимальным является сочетание полного масштабирования ($\text{mean}=\text{True}$, $\text{std}=\text{True}$) с линейными признаками ($\text{degree}=1$).

Выводы о проделанной работе

В ходе лабораторной работы была реализована и исследована линейная регрессия с различными комбинациями предобработки данных. Получены следующие выводы:

- Масштабирование признаков (StandardScaler) значительно снижает число обусловленности матрицы $X^T X$, но не влияет на MAE при $\text{degree}=1$.
- Увеличение степени полинома повышает качество на обучающей выборке, однако при $\text{degree} \geq 2$ модель переобучается: MAE test многократно превышает MAE train.
- Наилучшая комбинация параметров: $\text{mean}=\text{True}$, $\text{std}=\text{True}$, $\text{degree}=1$ - обеспечивает MAE test = 3.37 и минимальное число обусловленности.
- Число обусловленности является важным индикатором численной стабильности: при $\text{degree}=3$ оно достигает 1.25×10^{21} , что делает решение практически ненадёжным.
- Переобучение (overfitting) чётко диагностируется по расхождению MAE train и MAE test.