

# **ЛАБОРАТОРНАЯ РАБОТА №1**

## **Исследование влияния предобработки данных на качество линейной регрессии**

**Студенты: Альтшуль Даниил Евгеньевич,  
Вохмяков Данила Никитич**

Группа: J3117

Вариант: 17

test\_size = 0.23    random\_state = 46

# 1. Цель работы

---

Предложить среднеквадратическую аппроксимацию табличной функции многих переменных, проанализировать чувствительность точного решения к ошибкам округления, проверить сходимость расчётных и исходных данных.

## 2. Теоретические сведения

---

### 2.1 Линейная регрессия

Линейная регрессия — метод моделирования зависимости между зависимой переменной  $y$  и одной или несколькими независимыми переменными  $X$  по формуле:

$$y = Xw + \varepsilon$$

где  $w$  — вектор весов (коэффициентов),  $\varepsilon$  — случайная ошибка.

Оптимальные веса находятся через нормальное уравнение МНК:  $w^* = (X^T X)^{-1} X^T y$ , что эквивалентно решению системы линейных уравнений  $X^T X w = X^T y$  методом наименьших квадратов.

### 2.2 Методы предобработки данных

StandardScaler — стандартизация признаков: вычитание среднего (with\_mean) и деление на стандартное отклонение (with\_std). Приводит признаки к единому масштабу, что уменьшает число обусловленности матрицы и повышает численную стабильность.

PolynomialFeatures — генерация полиномиальных признаков заданной степени degree. Позволяет моделировать нелинейные зависимости в рамках линейной регрессии.

### 2.3 Метрики качества

MAE (Mean Absolute Error) — средняя абсолютная ошибка: среднее значение модуля разности между реальными и предсказанными значениями. Интерпретируется в единицах целевой переменной (тыс. долларов).

Число обусловленности матрицы  $X^T X$  — отношение максимального сингулярного числа к минимальному. Большое значение ( $>10^6$ ) указывает на численную нестабильность и чувствительность решения к малым ошибкам.

## 3. Ход работы

---

### 3.1 Описание датасета

Использован датасет Boston Housing (файл train.csv). Целевая переменная: medv — медианная стоимость жилья в тысячах долларов. Признаки: криминальная обстановка (crim), доля жилых зон (zn), доля нежилых площадей (indus), наличие реки (chas), концентрация оксидов азота (nox), среднее число комнат (rm), доля старого жилья (age), расстояние до центров занятости (dis), индекс транспортной доступности (rad), налог на собственность (tax), соотношение учитель/ученик (ptratio), доля чёрного населения (b), процент малообеспеченных жителей (lstat). Столбец ID исключался из признаков.

### 3.2 Листинг кода

Импорт библиотек

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler, PolynomialFeatures
from sklearn.model_selection import train_test_split
```

Загрузка данных и параметры варианта

```
train_df = pd.read_csv('train.csv')
test_df = pd.read_csv('test.csv')
TEST_SIZE = 0.23
RANDOM_STATE = 46
```

Основной эксперимент — цикл по 6 комбинациям

```
rules_from_pdf = [
    {'mean': False, 'std': False, 'degree': 1},
    {'mean': True, 'std': False, 'degree': 1},
    {'mean': False, 'std': True, 'degree': 1},
    {'mean': True, 'std': True, 'degree': 1},
    {'mean': True, 'std': True, 'degree': 2},
    {'mean': True, 'std': True, 'degree': 3},
]
res = []
for i, rls in enumerate(rules_from_pdf, 1):
    features = train_df.drop(columns=["medv", "ID"])
    target = train_df[["medv"]]
    X_train, X_test, y_train, y_test = train_test_split(
        features, target, test_size=TEST_SIZE, random_state=RANDOM_STATE)
```

```

scaler = StandardScaler(with_mean=rls['mean'], with_std=rls['std'])
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
poly = PolynomialFeatures(degree=rls['degree'])
X_train = poly.fit_transform(X_train)
X_test = poly.transform(X_test)
model = LinearRegression()
model.fit(X_train, y_train)
mae_train = mean_absolute_error(y_train, model.predict(X_train))
mae_test = mean_absolute_error(y_test, model.predict(X_test))
cond = np.linalg.cond(X_train.T @ X_train)
res.append({'M': i, 'mean': rls['mean'], 'std': rls['std'],
            'degree': rls['degree'], 'mae train': round(mae_train, 4),
            'mae test': round(mae_test, 4), 'cond': f'{cond:.2e}'})
table = pd.DataFrame(res)


```

### 3.3 Таблица результатов экспериментов

| № | mean  | std   | degree | MAE train | MAE test | Число обусл. |
|---|-------|-------|--------|-----------|----------|--------------|
| 1 | False | False | 1      | 3.4628    | 3.3667   | 2.36e+08     |
| 2 | True  | False | 1      | 3.4628    | 3.3667   | 1.13e+07     |
| 3 | False | True  | 1      | 3.4628    | 3.3667   | 1.25e+05     |
| 4 | True  | True  | 1      | 3.4628    | 3.3667   | 9.42e+01     |
| 5 | True  | True  | 2      | 1.5763    | 90.2035  | 1.08e+17     |
| 6 | True  | True  | 3      | 0.0000    | 16.5916  | 1.25e+21     |

## 4. Анализ результатов

### 4.1 Графики



### 4.2 Ответы на вопросы

— Как масштабирование признаков влияет на качество модели?

При  $\text{degree}=1$  масштабирование не изменяет MAE train и MAE test (во всех конфигурациях 1–4 значения одинаковы: 3.46 и 3.37 ).

Однако масштабирование кардинально снижает число обусловленности матрицы  $X^T X$ : без нормировки оно составляет  $2.36 \times 10^8$ , а при включении обоих параметров ( $\text{mean}=\text{True}$ ,  $\text{std}=\text{True}$ ) падает до  $9.42 \times 10^1$ . Это означает,

что решение становится значительно более численно устойчивым.

— Как изменяется качество при увеличении степени полинома?

При переходе с  $\text{degree}=1$  на  $\text{degree}=2$  MAE train снижается с 3.46 до 1.58 — модель начинает лучше описывать обучающую выборку. Однако MAE test растёт до 90.2, что говорит о сильном ухудшении обобщающей способности. При  $\text{degree}=3$  MAE train = 0 (идеал), но MAE test = 16.59 — модель полностью запоминает обучающие данные и не обобщается.

— Есть ли признаки переобучения (overfitting)?

Да, начиная с конфигурации №5 ( $\text{degree}=2$ ). Признаки: MAE train резко падает при одновременном росте MAE test. При  $\text{degree}=3$  разрыв максимальный: train=0.0000 против test=16.5916.

— Как число обусловленности связано с качеством модели?

Большое число обусловленности указывает на численную нестабильность: матрица  $X^T X$  близка к вырожденной, малые ошибки в данных приводят к большим ошибкам в весах. При  $\text{degree}=2$   $\text{cond}=1.08 \times 10^{17}$ , при  $\text{degree}=3$  —  $1.25 \times 10^{21}$ , что объясняет огромные MAE test. Масштабирование снижает  $\text{cond}$  на несколько порядков и стабилизирует решение.

— Какая комбинация параметров даёт наилучший результат на тестовой выборке?

Конфигурация №4:  $\text{mean}=\text{True}$ ,  $\text{std}=\text{True}$ ,  $\text{degree}=1$ . MAE test = 3.3667 — минимальное среди всех конфигураций, число обусловленности наименьшее ( $9.42 \times 10^1$ ). Модель не переобучена: MAE train  $\approx$  MAE test.

### 4.3 Выводы о влиянии предобработки на качество модели

Стандартизация признаков (StandardScaler) не улучшает MAE при линейной модели, но существенно снижает число обусловленности, повышая численную стабильность. Полиномиальные признаки позволяют снизить ошибку на обучающей выборке, однако при  $\text{degree} \geq 2$  без регуляризации неизбежно возникает переобучение. Оптимальным является сочетание полного масштабирования ( $\text{mean}=\text{True}$ ,  $\text{std}=\text{True}$ ) с линейными признаками ( $\text{degree}=1$ ).

## 5. Выводы о проделанной работе

---

В ходе лабораторной работы была реализована и исследована линейная регрессия с различными комбинациями предобработки данных. Были получены следующие выводы:

- Масштабирование признаков (StandardScaler) значительно снижает число обусловленности матрицы  $X^T X$ , но не влияет на MAE при степени полинома  $\text{degree}=1$ .
- Увеличение степени полинома повышает качество на обучающей выборке, однако при  $\text{degree} \geq 2$  модель переобучается: MAE test многократно превышает MAE train.
- Наилучшая комбинация параметров:  $\text{mean}=\text{True}$ ,  $\text{std}=\text{True}$ ,  $\text{degree}=1$  — обеспечивает MAE test=3.37 и минимальное число обусловленности.
- Число обусловленности является важным индикатором численной стабильности: при  $\text{degree}=3$  оно достигает  $1.25 \times 10^{21}$ , что делает решение практически ненадёжным.
- Переобучение (overfitting) чётко видно по расхождению MAE train и MAE test.