

Лабораторная работа №1

Исследование влияния предобработки данных на качество линейной регрессии

1 Цель работы

Предложить среднеквадратическую аппроксимацию табличной функции многих переменных, проанализировать чувствительность точного решения к ошибкам округления, проверить сходимость расчетных и исходных данных

2 Теоретические сведения

2.1 Линейная регрессия

Линейная регрессия — метод моделирования зависимости между зависимой переменной y и одной или несколькими независимыми переменными X :

$$y = X\mathbf{w} + \varepsilon \quad (1)$$

где $\mathbf{w}$ — вектор весов (коэффициентов), ε — случайная ошибка.

Задача обучения — найти оптимальные веса $\mathbf{w}$, минимизирующие функцию потерь. Для среднеквадратичной ошибки (MSE) решение имеет вид:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \|X\mathbf{w} - y\|^2 \quad (2)$$

Вопрос для размышления

Подумайте (или посмотрите в интернете), как задача линейной регрессии связана с решением системы линейных алгебраических уравнений (СЛАУ) методом наименьших квадратов (МНК)? Какую систему нужно решить, чтобы найти оптимальные веса $\mathbf{w}^*$?

3 Задание

3.1 Исходные данные

Датасет `housing.csv` содержит данные о ценах на жилье в Бостоне:

- **Целевая переменная:** MEDV — медианная стоимость жилья (в тысячах долларов)
- **Признаки** (13 столбцов): криминальная обстановка, доля жилых зон, расстояние до центров занятости, количество комнат и др.

3.2 Порядок выполнения работы

1. Загрузка данных

Загрузите датасет `housing.csv`. Выделите признаки X (все столбцы кроме `MEDV`) и целевую переменную y (столбец `MEDV`).

2. Проведение экспериментов

Для каждой комбинации параметров из таблицы вариантов (см. раздел 3.3) выполните следующие шаги:

- а) Разделите данные на обучающую и тестовую выборки с параметрами `test_size` и `random_state` согласно вашему варианту
- б) Примените предобработку данных:
 - `StandardScaler` с параметрами `with_mean` и `with_std`
 - `PolynomialFeatures` с параметром `degree`
- в) Обучите модель линейной регрессии (`LinearRegression`)
- г) Вычислите метрики:
 - `mean_absolute_error` на обучающей выборке
 - `mean_absolute_error` на тестовой выборке
 - Число обусловленности матрицы $X^T \times X$

3. Заполнение таблицы результатов

Заполните таблицу следующего вида:

№	StandardScaler		Poly	MAE		Число
	mean	std	degree	train	test	обусл.
1	False	False	1	...	...	...
2	True	False	1	...	...	...
3	False	True	1	...	...	...
4	True	True	1	...	...	...
5	True	True	2	...	...	...
6	True	True	3	...	...	...

Примечание: Проведите эксперименты для всех комбинаций параметров `StandardScaler` и нескольких значений `degree`.

4. Анализ результатов

Проанализируйте полученные результаты:

- Как масштабирование признаков влияет на качество модели?
- Как изменяется качество при увеличении степени полинома?
- Есть ли признаки переобучения (`overfitting`)? По каким признакам это видно?
- Как число обусловленности связано с качеством модели?
- Какая комбинация параметров дает наилучший результат на тестовой выборке?

3.3 Варианты заданий

Каждый студент выполняет работу с параметрами разбиения данных согласно своему варианту:

№	test	rand	№	test	rand	№	test	rand	№	test	rand
1	0.30	41	14	0.24	41	27	0.26	39	40	0.23	45
2	0.28	48	15	0.21	49	28	0.24	50	41	0.28	41
3	0.22	46	16	0.20	17	29	0.29	27	42	0.27	42
4	0.27	40	17	0.23	46	30	0.30	12	43	0.22	43
5	0.20	28	18	0.23	46	31	0.24	43	44	0.26	44
6	0.26	45	19	0.30	33	32	0.22	40	45	0.20	45
7	0.24	50	20	0.21	49	33	0.30	15	46	0.22	29
8	0.21	24	21	0.24	46	34	0.26	32	47	0.20	46
9	0.27	38	22	0.21	35	35	0.21	45	48	0.21	20
10	0.29	25	23	0.22	44	36	0.24	41	49	0.29	31
11	0.22	50	24	0.27	36	37	0.29	42	50	0.23	43
12	0.30	28	25	0.24	37	38	0.27	43			
13	0.21	18	26	0.26	24	39	0.22	44			

Примечание: test = test_size, rand = random_state

4 Требования к отчету

Отчет должен содержать:

1. **Титульный лист** с указанием названия работы, ФИО студента, группы, варианта
2. **Цель работы**
3. **Краткие теоретические сведения:**
 - Описание линейной регрессии
 - Описание методов предобработки данных
 - Описание метрик качества
4. **Ход работы:**
 - Описание датасета
 - Листинг кода с комментариями
 - Заполненная таблица результатов экспериментов
5. **Анализ результатов:**
 - Ответы на вопросы из раздела «Анализ результатов»
 - **Графики зависимости MAE от параметров**
 - Выводы о влиянии предобработки на качество модели
6. **Выводы** о проделанной работе

Формат: PDF-файл

Полезные ссылки

- Документация scikit-learn: <https://scikit-learn.org/>
- Датасет Boston Housing: <https://www.kaggle.com/c/boston-housing>
- Pandas documentation: <https://pandas.pydata.org/docs/>

Рекомендации по выполнению

- Начните с простых экспериментов (без предобработки)
- Постепенно добавляйте масштабирование и полиномиальные признаки
- Обращайте внимание на разницу между MAE на train и test
- Следите за числом обусловленности — большие значения указывают на проблемы
- Используйте Jupyter Notebook или Google Colab для удобства
- Сохраняйте промежуточные результаты